

T5: Proyecto Visión por computador: Identificación de cáncer, hiperplasia y pólipos en muestras histológicas de endometrios utilizando una arquitectura VGG16”

El cáncer de endometrio es una patología que se origina en el tejido que recubre el útero. Es una de las afecciones ginecológicas más comunes, sin embargo, la concientización sobre su existencia es aún muy escasa. El área de tumores ginecológicos es aún sub investigada y se necesita colaboración con herramientas tecnológicas para avanzar (Josua, Allen & Orsi, 2025).

Por lo anterior es que se busca utilizar la visión por computador para analizar un conjunto de muestras histopatológicas endométricas para la clasificación de endometrio: sano, hiperplasia, pólio y adenocarcinoma endometrial. Con el fin de identificar casos de anomalías, para la prevención temprana de un cáncer agresivo. Se evaluará el desempeño de la clasificación de estos casos con una arquitectura de redes neuronales pre entrenada. Se selecciona VGG16. No se comparará con otros modelos, sino distintas combinaciones de hiperparámetros.

Fuente de los datos y formato

El dataset es de un estudio en el tercer hospital afiliado de la Universidad de Zhengzhou. Se recolectaron 498 muestras de tejido endometrial. Desde donde se generaron 3,302 imágenes (jpeg). Estaban en un Zip disponible en Figshare, donde había directorios y subdirectorios.

Manejo de dimensiones

INTRODUCTION TO THE EXPERIMENTAL DATASET			
General class	Fine-grained class	Subtype	#Image Patches
Benign	Normal Endometrium	Luteal phase	600
		Menstrual phase	21
		Follicular phase	712
Malignant	Endometrial Polyp	NA	636
	Endometrial Hyperplasia	Simple	516
		Complex	282
Malignant	Endometrial Adenocarcinoma	NA	535
		Total:	3,302

Ilustración 1: Distribución de clases (Sun et al., 2019)

Para aplanar los directorios y poder trabajar la base de datos. Se usa de Keras las siguientes herramientas; `ImageDataGenerator` y `flow_from_directory`, que automáticamente identifican las clases y permite hacer la aumentación de los datos. Se maneja todo con las 4 clases principales. El tamaño del conjunto de validación es de 0.2 del total de train, no se hace un test directamente por el tipo de database y herramientas de Keras usadas.

Balance de clases

Es importante mencionar que, inicialmente no se balancearon las clases por olvido y se dejó el primero así y el resto se balancearon. Para ello se utilizan pesos automáticos en el training y al crear una instancia de VGG16 se utilizan los pesos de ‘Imagenet’.

Data augmentation

Se realizan las siguientes modificaciones: zoom, flip, brightness, shift, channel shift.

Implementación: Véase (Tabla 2)

Resultados:

Hubo problemas con la clasificación de imágenes benignas. Confusiones entre hiperplasia y pólipos, normal y carcinoma.

Se busca el mejor recall y precisión en EA. El mejor modelo fue el 2, con 0.61 y 0.34. El peor fue el modelo 3 con 0.12 y 0.72 respectivamente.

Es clave el shift alto/ancho bajo, luminosidad y canales de colores altos. Zoom medio bajo.

Conclusiones:

El probar un solo modelo con variaciones de hiperparámetros es un buen acercamiento para encontrar el potencial particular que puede ofrecer. Aunque la comparativa con otros es un paso para análisis futuros.

Por otro lado, si bien el dataset era de mediano tamaño la disponibilidad de imágenes del área es aún baja. De la misma forma el tipo de muestra histológica tiene una alta complejidad por el detalle de las estructuras y las tinciones utilizadas. El entrenamiento necesitó de bastos recursos computacionales, incluso si se usó un batch “pequeño” y un learning rate medio.

La partición del dataset está sujeta a discusión, considerando el formato anidado. La existencia de una división previa hubiera simplificado y evitado errores.

La aumentación de los datos es realmente compleja, y la cantidad de combinaciones de valores existentes hacen que los resultados presentes sean muy acotados. Además, valores muy agresivos pueden ser perjudiciales. Algunos shifts de alto y largo mueven mucho las estructuras. Zoom muy grande puede hacer que no se distinga el gran tamaño de las células en el cáncer. La variación de color y brillo si ayuda a identificar variaciones entre patologías por los cambios de tonos que se presentan distintivamente.

Utilización de máscaras o identificación de la imagen por estructuras geométricas o por núcleos podría mejorar el modelo. Por otro lado, modificaciones de color más complejas por las tinciones.

Finalmente, se considera muy relevante el consejo de profesionales que sepan de las variaciones entre tejidos y aquellos elementos que facilitan o dificultan los análisis.

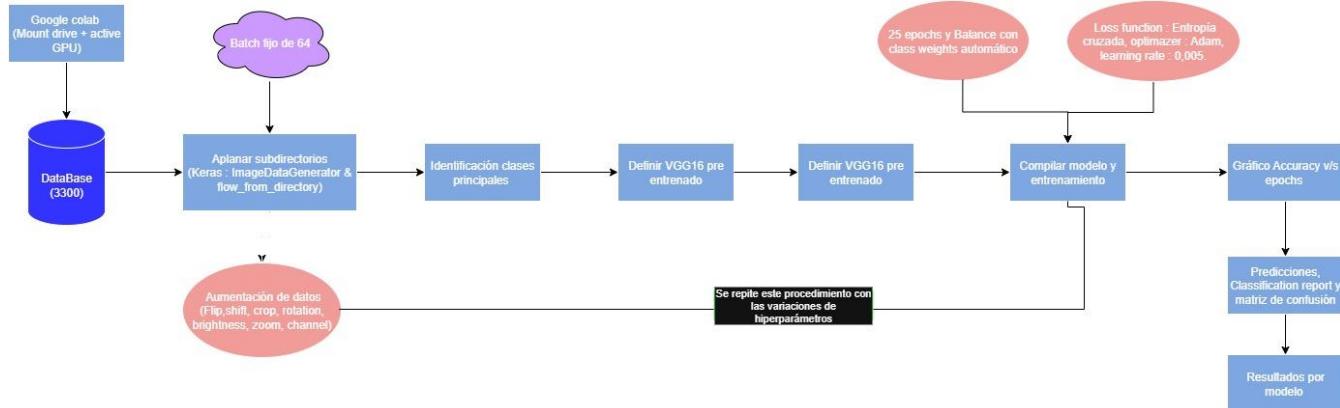


Ilustración 2: Implementación del proyecto (fuente : realización propia)

Referencias bibliográficas (Textos):

- Joshua, A., Allen, K. E., & Orsi, N. M. (2025). An Overview of Artificial Intelligence in Gynaecological Pathology Diagnostics. *Cancers*, 17(8), 1343. <https://doi.org/10.3390/cancers17081343>
- Sun, H., Zeng, X., Xu, T., Peng, G., & Ma, Y. (2019, 01 de octubre). Computer-Aided Diagnosis in Histopathological Images of the Endometrium Using a Convolutional Neural Network and Attention Mechanisms. *IEEE Journal of Biomedical and Health Informatics*, 24(4), 1076–1085. <https://doi.org/10.1109/JBHI.2019.2944977>
- Ali, M. A., El-Hameed, M. A., & Badr, A. W. (2024). Automated diagnosis of endometrial histopathological images using a hybrid attention-based transformer-convolutional neural network (AT-CNN). *Journal of Advanced Research*, 57, 41–55. <https://doi.org/10.1016/j.jare.2024.01.006>

Referencia bibliográfica (Código)

1. Cepel, T. H. (s. f.). *Feature Extraction and Fine-Tuning using VGG16* [Código fuente]. Kaggle. <https://www.kaggle.com/code/tolgahancepel/feature-extraction-and-fine-tuning-using-vgg16>
2. Chollet, F. (2016). *Building powerful image classification models using very little data*. Keras Blog. <https://blog.keras.io/building-powerful-image-classification-models-using-very-little-data.html>
3. Hassan, H., AlHaj, A., & Ahmad, S. (2025). Application of VGG16 Transfer Learning for Breast Cancer Detection. *Information*, 16(3), 227. <https://doi.org/10.3390/info16030227>
4. How to plot the accuracy and loss from this keras cnn model. (2021). Stack Overflow. <https://stackoverflow.com/questions/66785014/>
5. Do I need pretrained weights for Keras VGG16? (2018). Stack Overflow. [https://stackoverflow.com/questions/41908379/keras-plot-training-validation-and-test-set-accuracy/56807595#:~:text=4%2034%2043%20Comments,=True\)%20fig.show%2520fig.show\(\)\(\)](https://stackoverflow.com/questions/41908379/keras-plot-training-validation-and-test-set-accuracy/56807595#:~:text=4%2034%2043%20Comments,=True)%20fig.show%2520fig.show()())
6. Yıldırım, M., Yurtay, M., & Elçioğlu, İ. (2023). Medical image data augmentation: techniques, comparisons and interpretations. *Artificial Intelligence Review*, 56(4), 3121–3192. <https://doi.org/10.1007/s10462-023-10453-z>
7. j-l-m. (s. f.). *Keras using pretrained VGG16*. GitHub Gist. <https://j-l-m.github.io/Keras%20using%20pretrained%20VGG16/>
8. Melis, R. (s. f.). *VGG16 with bias end class weights* [Código fuente]. Kaggle. <https://www.kaggle.com/code/raimondomelis/vgg16-with-bias-end-class-weights>
9. How to set class weights for imbalanced classes in Keras? (2017). Data Science Stack Exchange. <https://datascience.stackexchange.com/questions/13490/how-to-set-class-weights-for-imbalanced-classes-in-keras>

10. Do I need pretrained weights for Keras VGG16? (2017). Stack Overflow.
<https://stackoverflow.com/questions/45383706/do-i-need-pretrained-weights-for-keras-vgg16>
11. Singh, V. (2018). *Fine Tuning Pre-Trained Model VGG-16*. Medium.
<https://medium.com/data-science/fine-tuning-pre-trained-model-vgg-16-1277268c537f>
12. DIAGNijmegen. (s. f.). *pathology-he-auto-augment: H&E tailored Randaugment: automatic data augmentation policy selection for H&E-stained histopathology* [Código fuente]. GitHub.
<https://github.com/DIAGNijmegen/pathology-he-auto-augment>